ANOVA

Resumen

Enunciado del problema

$$H_0:\ \mu_1 = \mu_2 = \mu_3 \ldots = \mu_n$$

No existe diferencia significativa entre las medias poblacionales

$$H_a: no\ todas\ las\ poblaciones\ son\ iguales$$

Existe diferencia significativa entre al menos una de las medias poblacionales

Supuestos

Para concluir por medio de ANOVA, se deben de cumplir las siguientes 3 condiciones, o supuestos

- La variable respuesta está normalmente distribuida
- La varianza de la variable respuesta, σ^2, es la misma en todas las poblaciones
- Las observaciones son independientes entre ellas

Diseño completamente aleatorizado

Si cada resultado procede de un mismo método completamente aleatorizado se realiza este procedimiento

$$n_T = n_1 + n_2 + n_3 \ldots n_j$$

(o el número total de observaciones entre todas las muestras)

Paso 1: Sacar estadística descriptiva para cada población

n $\qquad \bar{x} = \frac{\sum_{i=1}^{n} x_i}{n} \qquad s^2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}$

Paso 2: Calcular la media muestral general

$$\bar{\bar{x}} = \frac{\sum_{j=1}^{k}\sum_{i=1}^{n_j} x_{ij}}{n_T}$$

(o la media de todas las observaciones de todas las muestras)

Paso 3: A la media de cada población, restarle $\bar{\bar{x}}$, elevar la resta al cuadrado y multiplicarlo por el número de observaciones dentro de su población j

$$para\ cada\ población: n_j\left(\bar{x}_j - \bar{\bar{x}}\right)^2$$

Paso 4: sumar todos los resultados anteriores y dividir la sumatoria entre los grados de libertad asociados con SCTR (k-1) para calcular CMTR

$$CMTR = \frac{\sum_{j=1}^{k} n_j \left(\bar{x}_j - \bar{\bar{x}}\right)^2}{k-1}$$

$$SCTR = \sum_{j=1}^{k} n_j \left(\bar{x}_j - \bar{\bar{x}}\right)^2$$

Paso 5: para cada población, multiplicar su varianza por su número de elementos – 1

$$(n_j - 1) * s_j^2$$

Paso 6: sumar todos los resultados anteriores y dividirlos entre los grados de libertad correspondientes a SCE ($n_T - k$) para obtener CME

$$CME = \frac{\sum_{j=1}^{k} (n_j - 1) * s_j^2}{n_T - k}$$

$$SCE = \sum_{j=1}^{k} (n_j - 1) * s_j^2$$

Paso 7: calcular F, el estadístico de prueba para la igualdad de k medias poblacionales, y los grados de libertad para el numerador y denominador

$$F = \frac{CMTR}{CME}$$

$$gl_n = k - 1$$

$$gl_d = n_T - k$$

Paso 8: de tabla 4, obtener F_a de forma que cumpla con la significancia, y ambos grados de libertad

Tabla 4

Paso 9: Concluir en base a comparación de F y F_a

- Si $F < F_a$, no se rechaza la hipótesis nula, es decir no existe diferencia significativa para concluir que las medias poblacionales son diferentes
- Si $F \geq F_a$, se rechaza la hipótesis nula, es decir que es válido concluir que las medias poblacionales tienen diferencias significativas

Paso 10: Comprobar supuestos

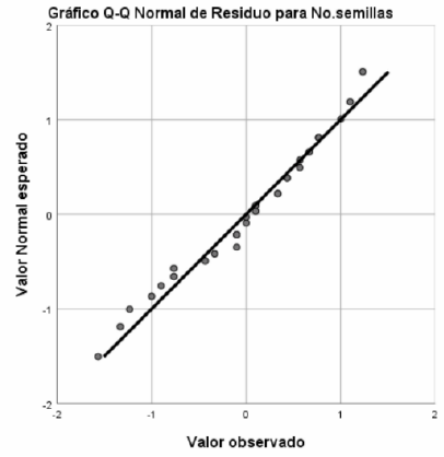
Normalidad

$$H_0: Existe\ normalidad\ en\ los\ residuales$$
$$H_a: No\ existe\ normalidad\ en\ los\ residuales$$

Prueba de Kolmogorov-Smirnov para una muestra

		Residuo para No.semillas
N		30
Parámetros normales[a,b]	Media	.0000
	Desv. Desviación	.73812
Máximas diferencias extremas	Absoluto	.146
	Positivo	.084
	Negativo	-.146
Estadístico de prueba		.146
Sig. asintótica(bilateral)		.102[c]

Se rechaza H_0 si el valor-p(sig. asintótica bilateral)≤α



ver que los residuos se ajusten a la línea de tendencia

Homocedasticidad (homogeneidad de varianzas)

$$H_0: Existe\ homogeneidad\ de\ varianzas\ debido\ al\ tratamiento$$
$$H_a: No\ existe\ homogeneidad\ de\ varianzas\ debido\ al\ tratamiento$$

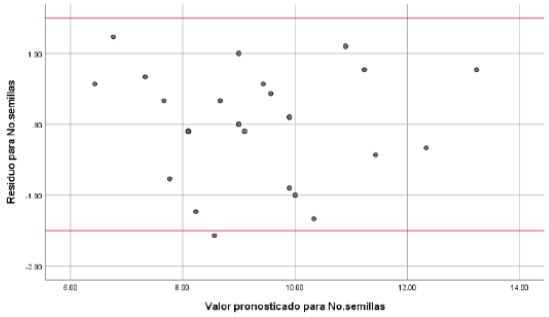
Prueba de homogeneidad de varianzas

		Estadístico de Levene	gl1	gl2	Sig.
No.semillas	Se basa en la media	1.485	2	27	.244

Rechazar si el valor p (sig.) ≤α

Independencia entre residuos

$$H_0: Existe\ independencia\ entre\ los\ residuales$$
$$H_a: No\ existe\ independencia\ entre\ los\ residuales$$



Se rechaza si los residuales siguen un patrón curvilíneo

Paso 11: LSD de Fisher (sólo si se rechaza la H_0 inicial y se cumplen los supuestos)

Si se rechaza a hipótesis nula inicial quiere decir que existe variación entre al menos una de las medias representa diferencias significativas. El LSD de Fisher sirve para determinar exactamente en cuál o cuáles. Esto se tiene que hacer cada vez para comparar cada media contra alguna contraparte. Entonces, si tengo 3 tratamientos, tengo que hacer 3 pruebas de forma que compare 1 con 2, 1 con 3 y 2 con 3. Si son 4, pasarían a ser 6 porque se puede comparar 1 con 2, 1 con 3, 1 con 4, 2 con 3, 2 con 4 y 3 con 4. El número de LSD de Fisher la sumatoria de los números consecutivos desde 1 hasta k (el número de tratamientos) -1.

$$\sum_{i=1}^{k-1} i$$

Plantear hipótesis

Vamos a suponer que *i* representa el primero de los tratamientos y *j*, el segundo

$$H_0: \mu_i = \mu_j$$
$$H_a: \mu_i \neq \mu_j$$

Calcular estadístico t

$$t = \left| \frac{\bar{x}_i - \bar{x}_j}{\sqrt{CME\left(\frac{1}{n_i} + \frac{1}{n_j}\right)}} \right|$$

Encontrar $t_{\alpha/2}$

En la tabla t, determinar $t_{\alpha/2}$, basado en los grados de libertad $n_T - k$.

Concluir en base a comparativo de t con $t_{\alpha/2}$

- Si $t \geq t_{\alpha/2}$, se rechaza H_0, es decir que existe diferencia significativa entre μ_i y μ_j
- De lo contrario, no se rechaza la hipótesis nula, es decir que no existe diferencia significativa entre μ_i y μ_j

Tabla ANOVA

Fuente de Variación	Suma de Cuadrados	Grados de libertad	Cuadrado Medio	F
Tratamientos	SCTR	$k-1$	CMTR	CMTR/CME
Error	SCE	$(k-1)(b-1)$	CME	
Total	STC	n_T-1		

Diseño por bloques aleatorizado

Si existe algún factor ajeno que podría hacer que el CME se vuelva más grande, se utiliza el diseño por bloques aleatorizado. Es decir, se podría utilizar otro instrumento para medir el mismo experimento en distintas repeticiones, el cual podría tener una calibración diferente. Es muy similar al diseño anterior, pero lleva otros factores para reducir el CME acorde a los bloques.

Paso 1: Sacar estadística descriptiva para cada población y para cada bloque

$$n \qquad \bar{x} = \frac{\sum_{i=1}^{n} x_i}{n} \qquad s^2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}$$

Paso 2: Calcular la media muestral general

$$\bar{\bar{x}} = \frac{\sum_{j=1}^{k}\sum_{i=1}^{b} x_{ij}}{n_T}$$

(también puede ser la media de todas las poblaciones, o la media de todos los bloques)

Paso 3: A cada observación, restarle $\bar{\bar{x}}$, y elevar la resta al cuadrado

$$para\ todas\ las\ observaciones: \left(x_{ij} - \bar{\bar{x}}\right)^2$$

Paso 4: Calcular la STC

Sumar todas las diferencias al cuadrado calculadas en el paso 3

$$STC = \sum_{i=1}^{b}\sum_{j=1}^{k}\left(x_{ij} - \bar{\bar{x}}\right)^2$$

Paso 5: Estimar la SCTR

Restar la media de cada tratamiento con la media muestral general, sumarlas todas y multiplicar la suma por el número de bloques

$$SCTR = b\sum_{j=1}^{k}\left(\bar{x}_j - \bar{\bar{x}}\right)^2$$

Paso 6: Calcular la SCBL

Restar la media de cada bloque con la media muestral general, sumarlas todas y multiplicar la suma por el número de tratamientos

$$SCBL = k\sum_{i=1}^{b}(\bar{x}_i - \bar{\bar{x}})^2$$

Paso 7: Determinar la SCE

Se calcula con los resultados calculados en los pasos 4, 5 y 6

$$SCE = STC - SCTR - SCBL$$

Paso 8: Calcular CMTR, CMBL y CME

Se calculan en base a los resultados calculados en los pasos 5, 6 y 7

$$CMTR = \frac{SCTR}{k-1} \qquad CMBL = \frac{SCBL}{b-1} \qquad CME = \frac{SCE}{(b-1)(k-1)}$$

Paso 9: Calcular F

Se calcula en base a lo calculado en el paso anterior

$$F = \frac{CMTR}{CME}$$

Paso 10: Calcular gl_n, gl_b y encontrar un F_a correspondiente a ambos y a α

$$gl_n = k - 1 \qquad gl_d = n_T - k$$

El valor de F_a se encuentra de la tabla F

Paso 11: Concluir en base a comparación de F y F_a

- Si $F < F_a$, no se rechaza la hipótesis nula, es decir no existe diferencia significativa para concluir que las medias poblacionales son diferentes
- Si $F \geq F_a$, se rechaza la hipótesis nula, es decir que es válido concluir que las medias poblacionales tienen diferencias significativas

Paso 12: Comprobar supuestos

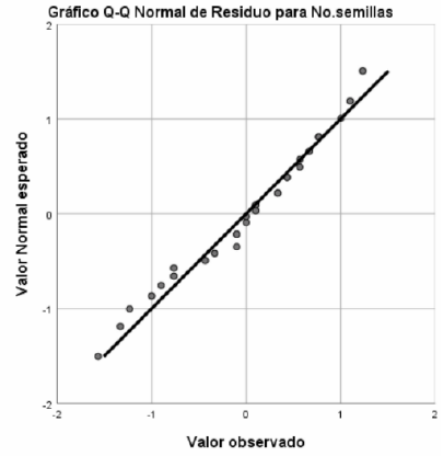
Normalidad

$$H_0: Existe\ normalidad\ en\ los\ residuales$$
$$H_a: No\ existe\ normalidad\ en\ los\ residuales$$

Prueba de Kolmogorov-Smirnov para una muestra

		Residuo para No.semillas
N		30
Parámetros normales[a,b]	Media	.0000
	Desv. Desviación	.73812
Máximas diferencias extremas	Absoluto	.146
	Positivo	.084
	Negativo	-.146
Estadístico de prueba		.146
Sig. asintótica(bilateral)		.102[c]

Se rechaza H_0 si el valor-p(sig. asintótica bilateral)≤α



ver que los residuos se ajusten a la línea de tendencia

Homocedasticidad (homogeneidad de varianzas)

Homogeneidad de varianzas debido al tratamiento

$$H_0: Existe\ homogeneidad\ de\ varianzas\ debido\ al\ tratamiento$$
$$H_a: No\ existe\ homogeneidad\ de\ varianzas\ debido\ al\ tratamiento$$

Prueba de homogeneidad de varianzas

		Estadístico de Levene	gl1	gl2	Sig.
No.semillas	Se basa en la media	1.485	2	27	.244

Rechazar si el valor p (sig.) ≤α

Homogeneidad de varianzas debido a los bloques

$$H_0: Existe\ homogeneidad\ de\ varianzas\ debido\ a\ los\ bloques$$
$$H_a: No\ existe\ homogeneidad\ de\ varianzas\ debido\ a\ los\ bloques$$

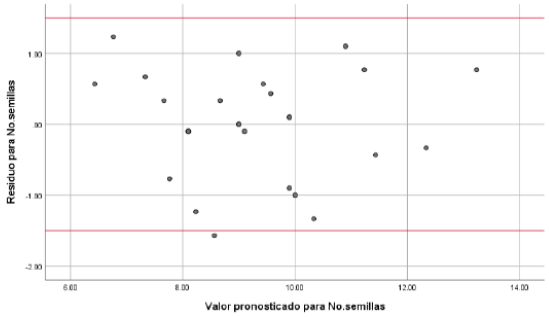
Prueba de homogeneidad de varianzas

		Estadístico de Levene	gl1	gl2	Sig.
No.semillas	Se basa en la media	1.485	2	27	.244

Rechazar si el valor p (sig.) ≤α

Independencia entre residuos

$$H_0: Existe\ independencia\ entre\ los\ residuales$$
$$H_a: No\ existe\ independencia\ entre\ los\ residuales$$



Se rechaza si los residuales siguen un patrón curvilíneo

Paso 13: LSD de Fisher (sólo si se rechaza la H_0 inicial y se cumplen los supuestos)

Si se rechaza a hipótesis nula inicial quiere decir que existe variación entre al menos una de las medias representa diferencias significativas. El LSD de Fisher sirve para determinar exactamente en cuál o cuáles. Esto se tiene que hacer cada vez para comparar cada media contra alguna contraparte. Entonces, si tengo 3 tratamientos, tengo que hacer 3 pruebas de forma que compare 1 con 2, 1 con 3 y 2 con 3. Si son 4, pasarían a ser 6 porque se puede comparar 1 con 2, 1 con 3, 1 con 4, 2 con 3, 2 con 4 y 3 con 4. El número de LSD de Fisher la sumatoria de los números consecutivos desde 1 hasta k (el número de tratamientos) -1.

$$\sum_{i=1}^{k-1} i$$

Plantear hipótesis

Vamos a suponer que *i* representa el primero de los tratamientos y *j*, el segundo

$$H_0: \mu_i = \mu_j$$
$$H_a: \mu_i \neq \mu_j$$

Calcular estadístico t

$$t = \left| \frac{\bar{x}_i - \bar{x}_j}{\sqrt{CME\left(\frac{1}{n_i} + \frac{1}{n_j}\right)}} \right|$$

Encontrar $t_{\alpha/2}$

En la tabla t, determinar $t_{\alpha/2}$, basado en los grados de libertad $n_T - k$.

Concluir en base a comparativo de t con $t_{\alpha/2}$

- Si $t \geq t_{\alpha/2}$, se rechaza H_0, es decir que existe diferencia significativa entre μ_i y μ_j
- De lo contrario, no se rechaza la hipótesis nula, es decir que no existe diferencia significativa entre μ_i y μ_j

Tabla ANOVA

Fuente de Variación	Suma de Cuadrados	Grados de libertad	Cuadrado Medio	F
Tratamientos	SCTR	$k-1$	CMTR	CMTR/CME
Bloques	SCBL	$b-1$	CMBL	
Error	SCE	$(k-1)(b-1)$	CME	
Total	STC	n_T-1		

ANOVA multifactorial

Permite concluir simultáneamente acerca de 2 o más factores. Es muy similar al procedimiento de bloques, pero se cambian más variables entre cada experimentación. Se tratan los efectos principales de los factores y el efecto de la interacción entre los factores.

Paso 1: Sacar promedios para cada combinación de tratamientos, y para cada tratamiento individual

$$\bar{x} = \frac{\sum_{i=1}^{n} x_i}{n}$$

Paso 2: Calcular la media muestral general

$$\bar{\bar{x}} = \frac{\sum_{j=1}^{b}\sum_{i=1}^{a} x_{ij}}{n_T}$$

Paso 3: A cada observación, restar la media muestral general y elevar el resultado al cuadrado

$$\left(x_{ijk} - \bar{\bar{x}}\right)^2$$

Paso 4: Calcular la suma total de cuadrados

Se calcula sumando todos los resultados anteriores

$$STC = \sum_{i=1}^{a}\sum_{j=1}^{b}\sum_{k=1}^{r}\left(x_{ijk} - \bar{\bar{x}}\right)^2$$

Paso 5: Restar la media muestral general de cada media de tratamientos y elevar el resultado al cuadrado

$$(\bar{x}_{i\cdot} - \bar{\bar{x}})^2 \qquad \left(\bar{x}_{\cdot j} - \bar{\bar{x}}\right)^2$$

Paso 6: Calcular la suma de cuadrados de ambos factores

Se calculan a partir de la sumatoria los resultados del paso anterior, *a, b* y *r*

$$SCA = br\sum_{i=1}^{a}(\bar{x}_{i\cdot} - \bar{\bar{x}})^2 \qquad SCB = ar\sum_{i=1}^{b}\left(\bar{x}_{\cdot j} - \bar{\bar{x}}\right)^2$$

Paso 7: A cada media muestral de observaciones individuales, restarles las medias por sus tratamientos y sumarles la media muestral general. Elevar el resultado al cuadrado

$$\left(\bar{x}_{ij} - \bar{x}_{i\cdot} - \bar{x}_{\cdot j} + \bar{\bar{x}}\right)^2$$

Paso 8: Determinar SCAB

La sumatoria de todos los resultados del paso anterior, multiplicado por r

$$SCAB = r \sum_{i=1}^{a} \sum_{j=1}^{b} \left(\bar{x}_{ij} - \bar{x}_{i\cdot} - \bar{x}_{\cdot j} + \bar{\bar{x}}\right)^2$$

Paso 9: Determinar SCE

Se determina con los resultados de los pasos 4, 6 y 8

$$SCE = STC - SCA - SCB - SCAB$$

Paso 10: Completar los datos de la tabla ANOVA

Tabla ANOVA

Fuente de Variación	**Suma de cuadrados**	**Grados de Libertad**	**Cuadrado medio**	**F**
Factor A	SCA	$a-1$	$CMA = \frac{SCA}{a-1}$	$\frac{CMA}{CME}$
Factor B	SCB	$b-1$	$CMB = \frac{SCB}{b-1}$	$\frac{CMB}{CME}$
Interacción	SCAB	$(a-1)(b-1)$	$CMAB = \frac{SCAB}{(a-1)(b-1)}$	$\frac{CMAB}{CME}$
Error	SCE	$ab(r-1)$	$CME = \frac{SCE}{ab(r-1)}$	
Total	STC	$n_T - 1$		

Paso 11: Determinar F_a para cada fuente de variación en la tabla ANOVA

Se determina con la tabla F, de acuerdo con α y los grados de libertad de cada fuente de variación

Paso 12: Concluir en base a cada comparación de F con F_a

- Si en algún caso para los que $F \geq F_a$ proviene de algún factor, se puede concluir que el tratamiento genera variaciones significativas. De lo contrario, el tratamiento no presenta variaciones significativas
- Si $F \geq F_a$ en la interacción, se puede concluir que la interacción entre los factores genera variaciones significativas. De lo contrario, la interacción entre los tratamientos no genera variaciones significativas

Paso 12: Comprobar supuestos

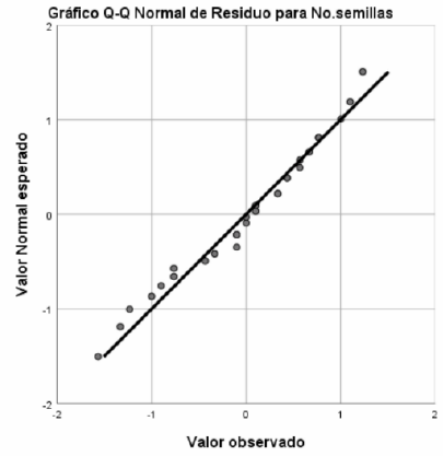
Normalidad

$$H_0: Existe\ normalidad\ en\ los\ residuales$$
$$H_a: No\ existe\ normalidad\ en\ los\ residuales$$

Prueba de Kolmogorov-Smirnov para una muestra

		Residuo para No.semillas
N		30
Parámetros normales[a,b]	Media	.0000
	Desv. Desviación	.73812
Máximas diferencias extremas	Absoluto	.146
	Positivo	.084
	Negativo	-.146
Estadístico de prueba		.146
Sig. asintótica(bilateral)		.102[c]

Se rechaza H_0 si el valor-p(sig. asintótica bilateral)≤α



ver que los residuos se ajusten a la línea de tendencia

Homocedasticidad (homogeneidad de varianzas)

Homogeneidad de varianzas debido al tratamiento A

$$H_0: Existe\ homogeneidad\ de\ varianzas\ debido\ al\ tratamiento\ A$$
$$H_a: No\ existe\ homogeneidad\ de\ varianzas\ debido\ al\ tratamiento\ A$$

Prueba de homogeneidad de varianzas

		Estadístico de Levene	gl1	gl2	Sig.
No.semillas	Se basa en la media	1.485	2	27	.244

Rechazar si el valor p (sig.) ≤α

Homogeneidad de varianzas debido al tratamiento B

$$H_0: Existe\ homogeneidad\ de\ varianzas\ debido\ al\ tratamiento\ B$$
$$H_a: No\ existe\ homogeneidad\ de\ varianzas\ debido\ al\ tratamiento\ B$$

Prueba de homogeneidad de varianzas

		Estadístico de Levene	gl1	gl2	Sig.
No.semillas	Se basa en la media	1.485	2	27	.244

Rechazar si el valor p (sig.) ≤α

Homogeneidad de varianzas debido a la interacción de tratamientos

$$H_0: Existe\ homogeneidad\ de\ varianzas\ debido\ a\ la\ interacción$$
$$H_a: No\ existe\ homogeneidad\ de\ varianzas\ debido\ a\ la\ interacción$$

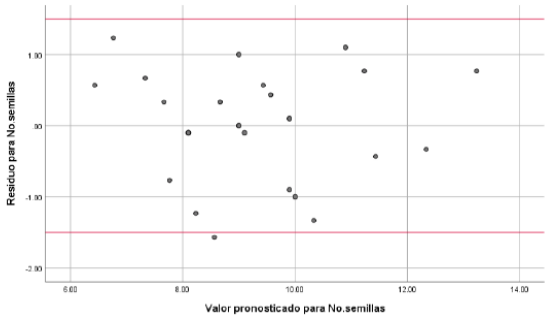
Prueba de homogeneidad de varianzas

		Estadístico de Levene	gl1	gl2	Sig.
No.semillas	Se basa en la media	1.485	2	27	.244

Rechazar si el valor p (sig.) ≤α

Independencia entre residuos

$$H_0: Existe\ independencia\ entre\ los\ residuales$$
$$H_a: No\ existe\ independencia\ entre\ los\ residuales$$



Se rechaza si los residuales siguen un patrón curvilíneo

Estadística descriptiva

Media muestral

$$\bar{x} = \frac{\sum_{i=1}^{n} x_i}{n}$$

Varianza muestral

$$s^2 = \frac{\sum_{i=1}^{n} (x_i - \bar{x})^2}{n-1}$$

Variables

H_0:Hipótesis nula
H_a: Hipótesis alternativa
μ: media poblacional
σ^2: varianza poblacional
$\bar{x}$: media muestral
s^2: varianza muestral
n: número de observaciones en una muestra
k: número de poblaciones
i: i-ésima observación
j: j-ésima población
$\bar{\bar{x}}$: media muestral general
$CMTR$: cuadrado medio debido a tratamientos
$SCTR$: suma de cuadrados debido a tratamientos
CME: Cuadrado medio debido al error
SME: Suma de cuadrados debido al error (completamente aleatorizado)
F: estadístico de prueba para la igualdad de k medias poblacionales
gl_n: grados de libertad del numerador
gl_d: grados de libertad del denominador

b: número de bloques
STC: suma total de cuadrados
$SCBL$: suma de cuadrados debido a los bloques
SCE: suma de cuadrados debido al error (bloques)
$CMBL$: cuadrado medio debido a los bloques

Multifactorial

a: número de niveles del factor *a*
b: número de niveles del factor *b*
r: número de replicaciones
i: *i-ésimo* tratamiento
j: *j-ésimo* tratamiento
k: *k-ésima* réplica
$\bar{x}_{i.}$: media muestral de las observaciones en el tratamiento i
$\bar{x}_{.j}$: media muestral de las observaciones en el tratamiento j
$\bar{x}_{ij}$: media muestral de las observaciones correspondientes a la combinación de los tratamientos *i* y *j*
$SCAB$: suma de cuadrados debido a la interacción