Universidad del Valle de Guatemala

Facultad de Ingeniería

Análisis Estadístico de Datos y Simulación

Catedrático: Ing. Javier Gurdián

Proyecto Final

Análisis de Afluencia Vehicular

Gabriel Monzón; Carné 17072

Efraín Recinos; Carné 17015

Daniel Regalado; Carné 18113

Jorge Urruela; Carné 18133

Jairon Velásquez, Carné 17156

Sección 40

Guatemala, 5 de junio de 2022

Tabla de contenido

Introducción 3
Objetivos 4
Objetivo general 4
Objetivos específicos 4
Metodología 4
Resultados e Interpretación 5
Conclusiones 16
Bibliografía 17
Anexos 17

Introducción

En este caso se tienen dos datasets basados en el tráfico de la región de Gran Bretaña. Se cuentan con una recopilación de datos que fue tomada por el semáforo y otra de las calles con mayor afluencia vehicular (más tránsito).

Los datos analizados se encuentran en el dataset *region_traffic.csv* los cuales contienen datos recopilados debido al comportamiento del tránsito dividido por regiones. Por otro lado el dataset *region_traffic.csv* nos indica los datos del comportamiento en ciertas fechas aleatorias para determinar los parámetros del comportamiento del tránsito en una de las calles más transitadas y periférica de toda la región.

Se busca conocer el resumen de los datos del tránsito en la región y la resolución a una serie de cuestiones probabilísticas del tráfico para saber si invertir o no en nuevas rutas y alternativas para la reducción y organización del tráfico.

A continuación, se describirán las variables para *region_traffic.csv:*

VARIABLE	DEFINICIÓN
Region_id	Es el identificador de la región del sitio web.
Region_name:	Nombre de la region
Road_category_id: .	Como se clasifican según tipo de carretera
Road_category_name:	Como se clasifican según el tipo de carretera.
Road_category_description:	Descripción de la clasificación del tipo de carretera.
Total_link_length_km:	Es la longitud total del enlace vial de la red de carreteras para esa región (en kilómetros).
Total_link_length_miles:	Es la longitud total del enlace vial de la red para esa región (en millas).
Pedal_cycles	Estimación del tráfico vial anual para bicicletas de pedales en la región y carretera dadas categoría.
two_wheeled_motor_vehicles	Es una estimación anual del tráfico por carretera para vehículos de motor de dos ruedas.
Cars_and_taxis	Es una estimación anual de tráfico por carretera para automóviles y taxis en la región dada y categoría vial.
Buses_and_coaches	Es una estimación del tráfico rodado anual de autobuses y autocares en la región y categoría de vía.
lgvs	Es una estimación del tráfico vial anual para LGV en la región y categoría de carretera dadas.

All_HGVs	Es una estimación anual del tráfico por carretera para todos los HGV en la región y categoría de carretera dadas.
All_motor_vehicles:	Es una estimación anual del tráfico por carretera para todos los vehículos motorizados en la región dada y categoría de vía

Por último, se describen las dos variables para *region_traffic.csv:*

timestamp	Se refiere a la variable que describe el tiempo en la que fue tomada la muestra.
hourly_traffic_count	Es el conteo de vehículos que transitaron en el periodo estipulado en timestamp

Objetivos

Objetivo general

- Realizar un análisis estadístico y evaluar los datos para determinar si es necesario invertir en nuevas rutas para la reducción del tráfico.
- Determinar estrategias a implementar para reducir el tráfico en gran bretaña

Objetivos específicos

- Determinar las horas con mas afluencia vehicular por medio del análisis EDA y de simulación para a partir de esto recomendar un plan de acción para la reducción del tránsito.
- Realizar una simulación con los parámetros de cada base de datos con la finalidad de observar el comportamiento vehicular el cual es de interés en Gran Bretaña
- Concluir en base a los resultados cuantitativos y visuales obtenidos con las herramientas Python, R y Power BI.

Metodología

Como primer punto se realizó un EDA para conocer el panorama general y específico acerca de los datos recopilados en *región_traffic.csv*. El EDA se realizó en Python en la cual se resume estadísticamente el dataset. Además, en la sección de resultados se hizo un resumen de carácter visual realizado en Power BI. Con los datos de traffic_flow.csv se obtuvieron los parámetros necesarios para así poder realizar una simulación las cuales nos ayudó a conocer el flujo de tráfico esperado a las horas de mayor afluencia para un corto plazo a futuro por hora y por día de la semana. Se modelaron dichos resultados obtenidos en R. La definición de las variables se presenta a continuación:

EDA de la librería región traffic fue realizado mediante Python, haciendo uso de las librerías numpy y pandas. Se baso el análisis en diagramas de fácil compresión tales como caja y bigotes y de barras apiladas y de líneas ya que el tipo de datos permitió una adecuada filtración de resultados haciendo uso de estas

herramientas. La agrupación de datos de la librería traffic Flow se realizó mediante power BI haciendo uso de sus tablas dinámicas para poder definir mediante medias los valores de flujo vehicular.

La simulación se realizó haciendo uso de R, no se utilizaron librerías para la simulación externas solo funciones tales como rexp para generar números aleatorios dado una lambda. La simulación se generó mediante 200 iteraciones sobre un mismo lambda, dichas iteraciones se almacenaron en una lista la cual fue utilizada para obtener media, desviación estándar, máximo y mínimo de la simulación. La media fue contada como el valor esperado.

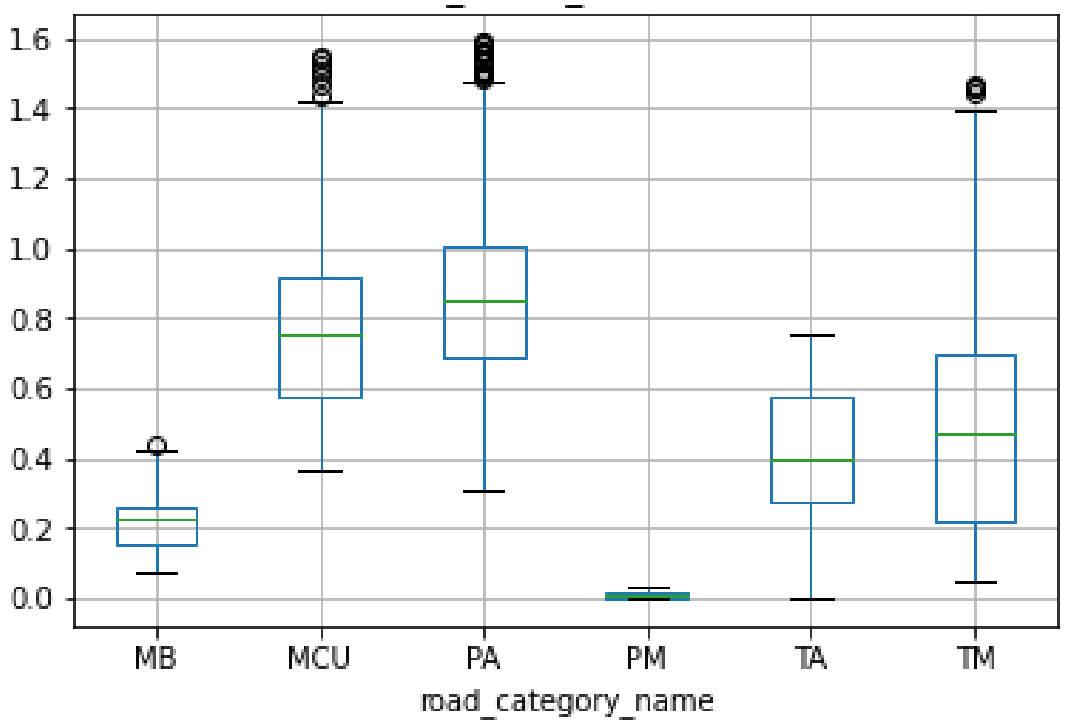
La determinación de probabilidad de flujo vehicular a las 4am y 5am se realizó mediante Excel haciendo una agrupación de la cantidad de vehículos que pasaban en periodos de 5min, en las horas previamente mencionadas.

Resultados e Interpretación

EDA y Visualización

Para iniciar, se realizó un diagrama de caja y bigotes de acuerdo con el tipo de carretera para ver si había algún dato atípico en alguna carretera de tipo 2 o inferior. De esta forma, se determinaría si es necesaria una mejora en alguna de las autopistas inferiores.

Gráfico 1. Diagrama de caja y bigotes de acuerdo con la categoría de la carretera.

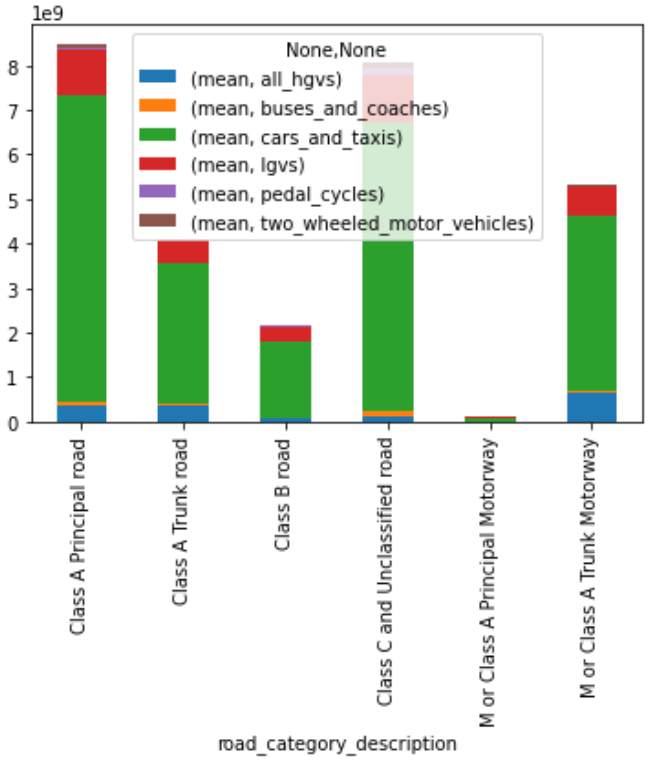


Se observa que no hay datos atípicos con una excepción muy ligera en el caso de las carreteras de clase B. Se recomienda clasificar bien las de iniciales MCU ya que parece que hay varias carreteras en su caso

que podrían necesitar unas mejoras, pero al incluir las que no están clasificadas correctamente, es imposible concluir al respecto.

Posteriormente, se realizó una gráfica para observar la distribución de los tipos de vehículo de acuerdo con la clasificación de la carretera y el flujo promedio.

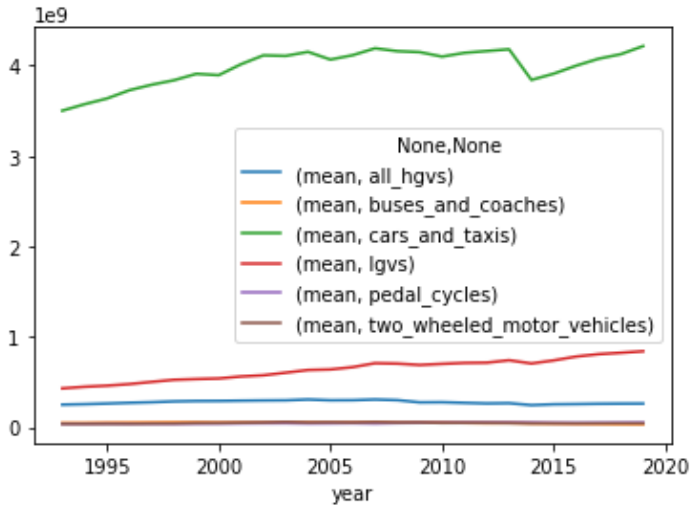
Gráfico 2. Gráfico de barras de acuerdo con el flujo promedio por tipo de carretera, superpuestos por tipo de vehículo.



Como es de esperar, todos los tipos de carretera muestran proporciones similares. Existe una mayor proporción de vehículos de carga pesada en la clase M para vehículos de este tipo, como también es de esperar.

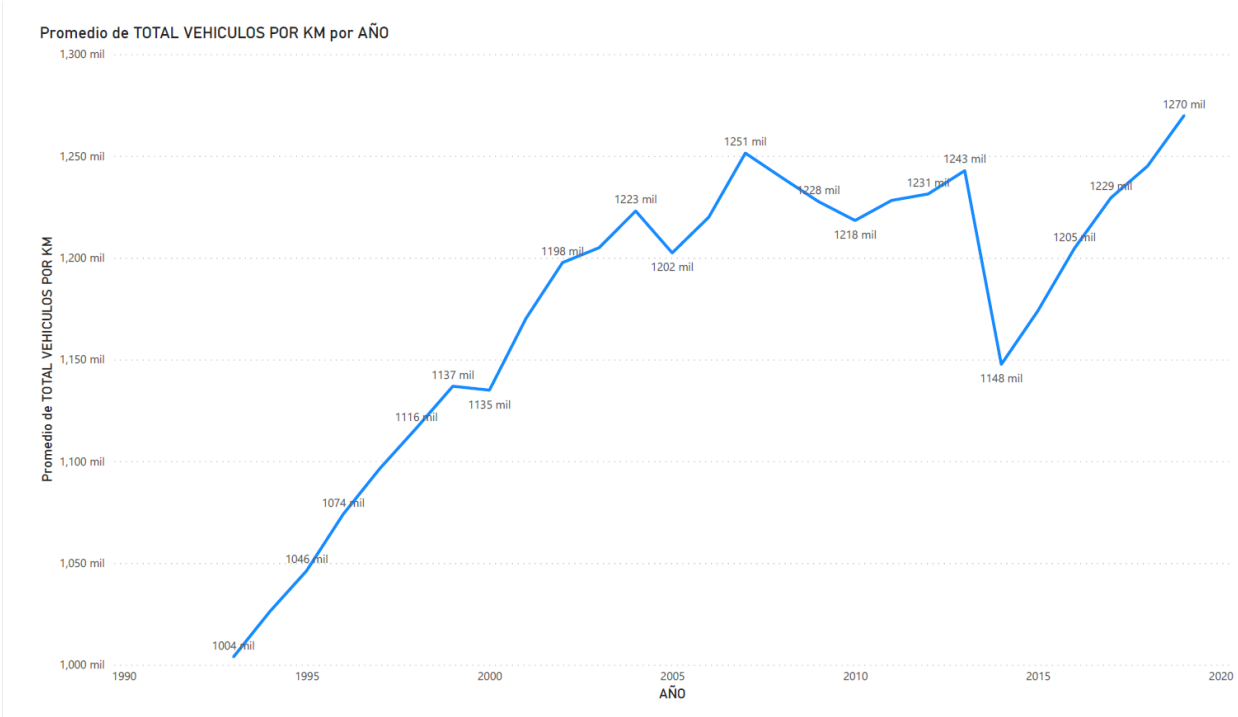
Adicionalmente, se realizó un gráfico de líneas para medir la evolución de los tipos de vehículo.

Gráfico 3. Evolución en la circulación de vehículos de acuerdo con su clasificación



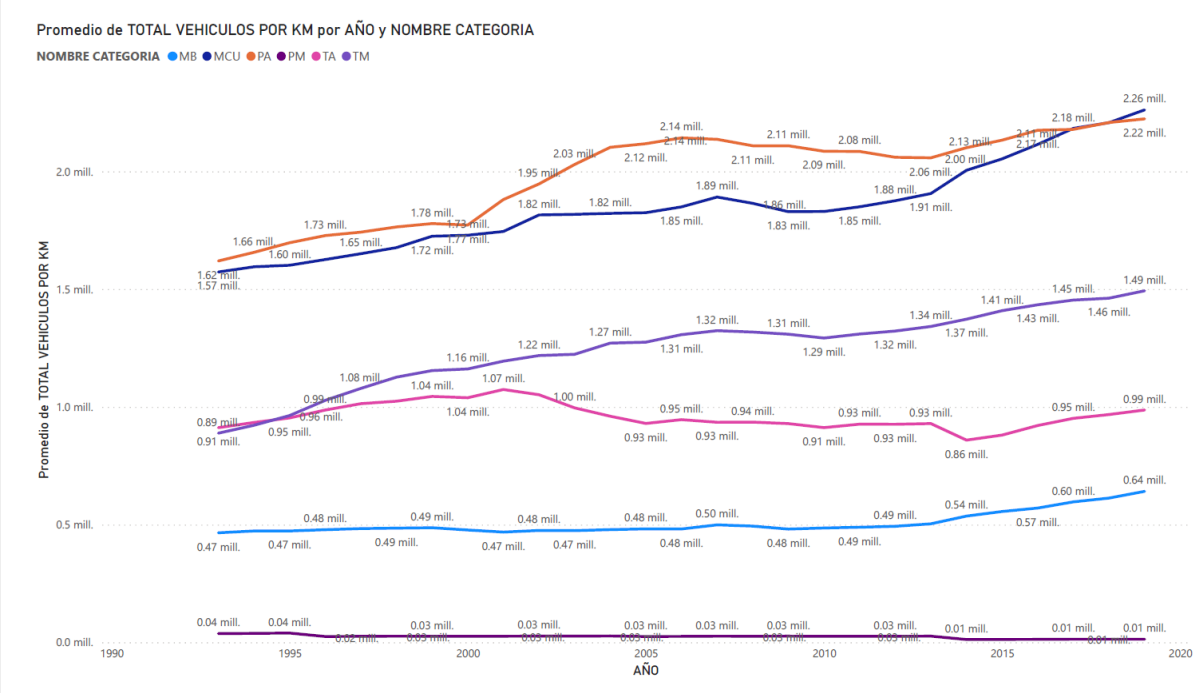
Se observa un crecimiento importante en carros y taxis, además de vehículos de carga ligera. Se observa también bastante decrecimiento en los vehículos de carga pesada.

Gráfico 4. Evolución en la circulación de vehículos por año en general



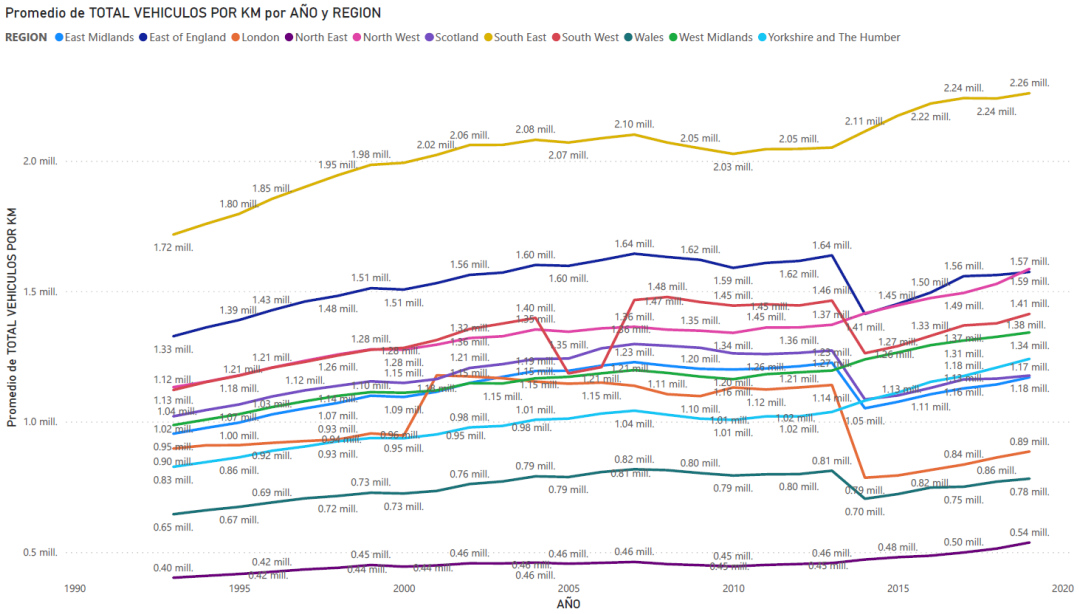
En esta gráfica observamos el comportamiento de la afluencia en promedio de vehículos por km por año.

Gráfico 5. Evolución en la circulación de vehículos por año por categoría de carretera



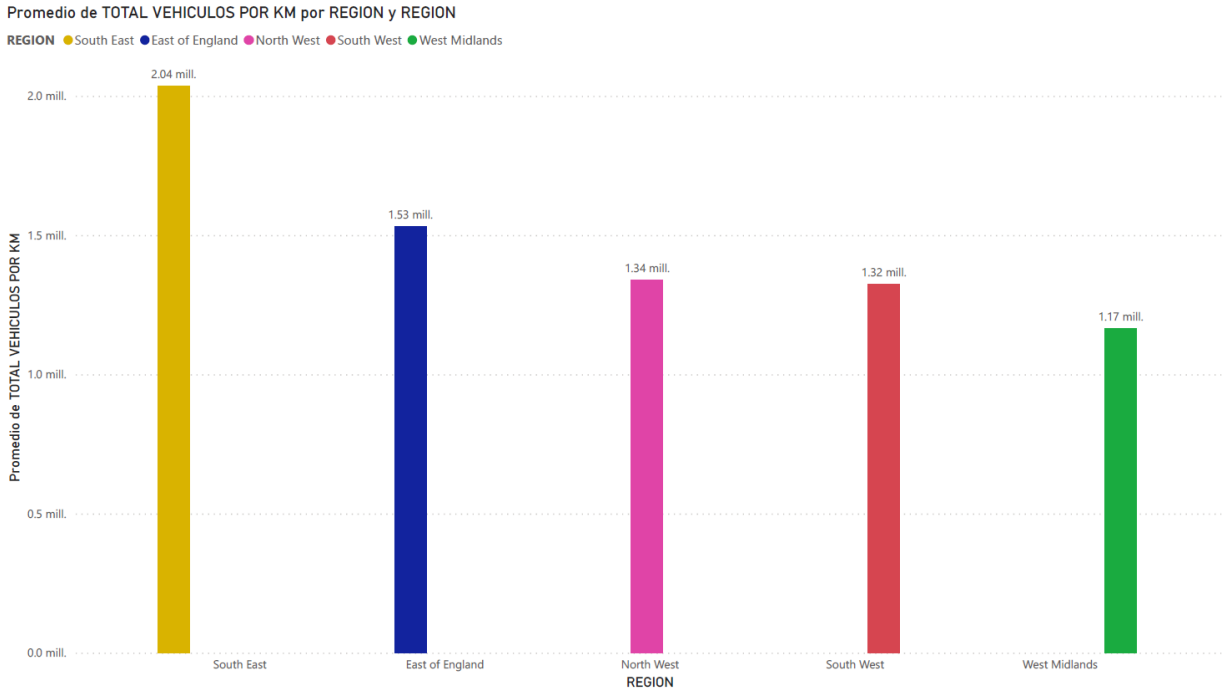
En este grafico observamos el comportamiento del promedio del total de vehiculos por km según el tiempo.

Gráfico 6. Evolución en la circulación de vehículos por año por región



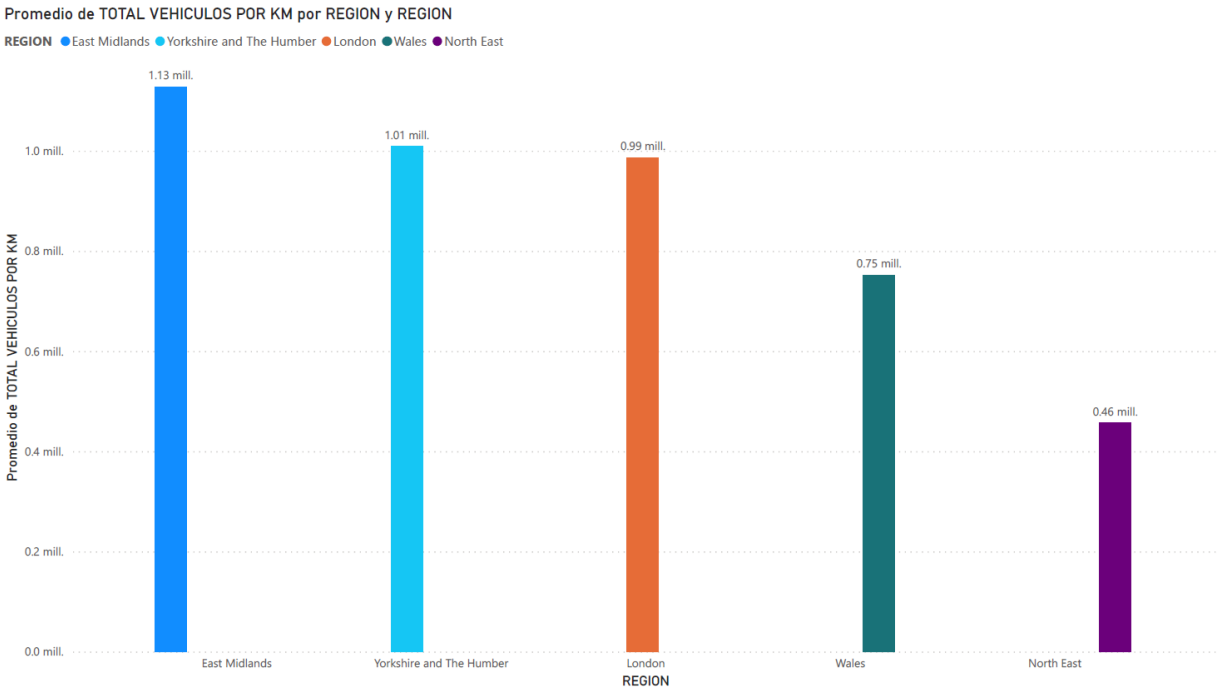
Se observa el comportamiento del promedio del total de vehículos por km según el tiempo por región. Se observa una caída del promedio de vehículos por km en varias regiones del año 2013 al año 2014.

Gráfico 7. Top 5 regiones con mayor afluencia promedio del total de vehículos por km



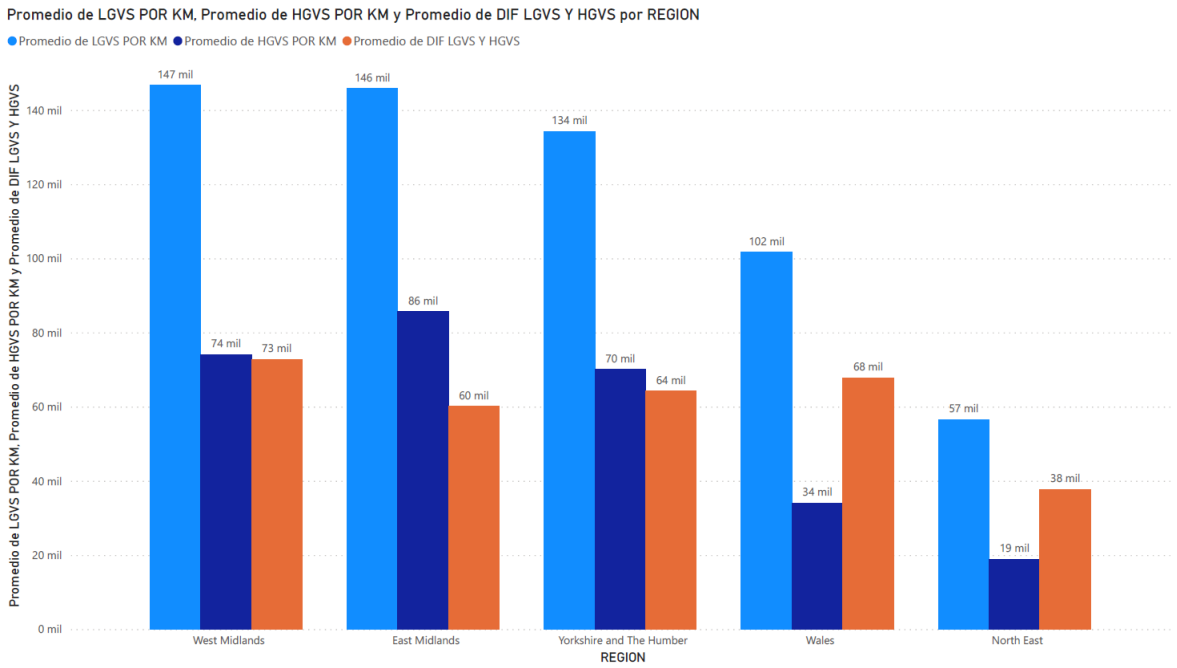
Se observan cuales son las cinco regiones con mayor afluencia promedio de vehículos por km.

Gráfico 8. Bottom 5 regiones con mayor afluencia promedio del total de vehículos por km



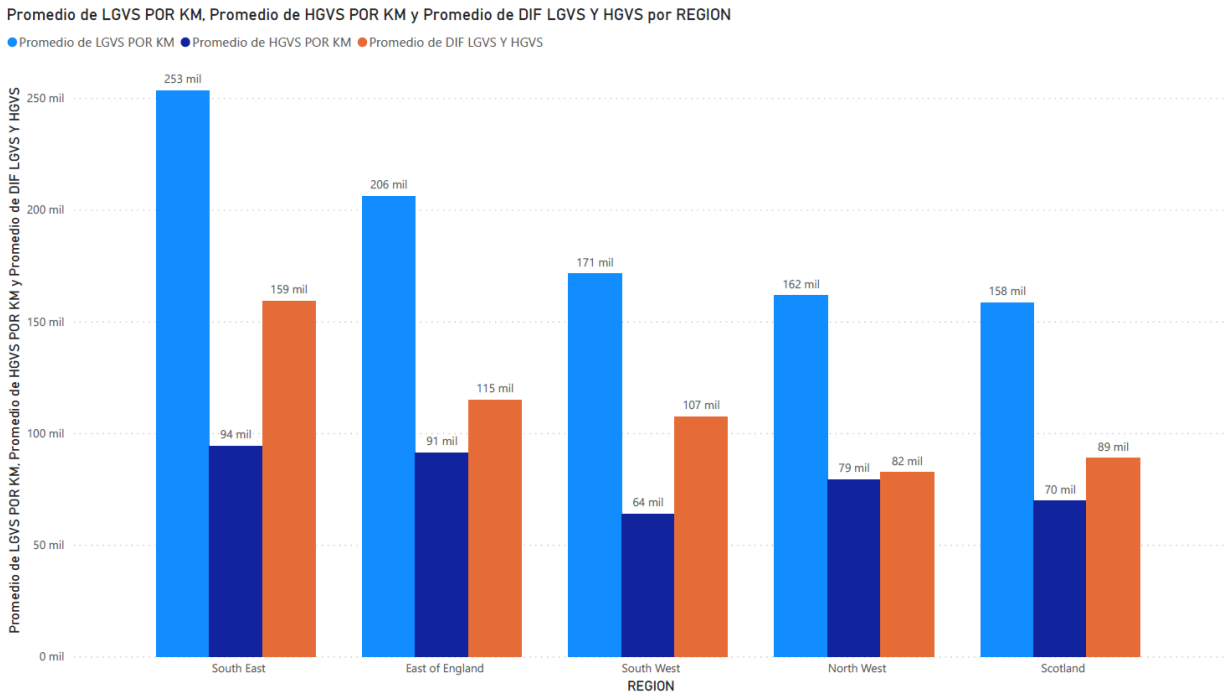
Se observan las cinco regiones con menor afluencia promedio de vehículos por km.

Gráfico 9. Top 5 regiones con mayor diferencia entre el promedio LGVS y HGVS



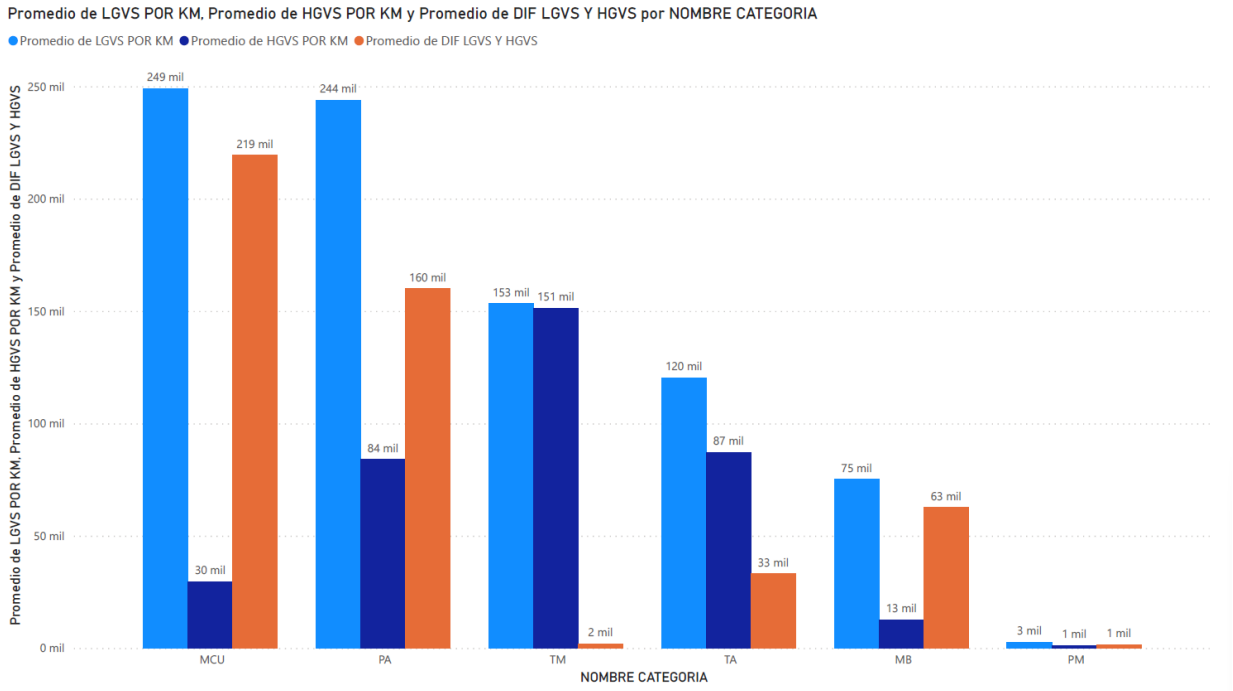
Estas son las 5 regiones donde se tiene mayor diferencia de la afluencia promedio de vehículos LGVS por km en comparación a los vehículos HGVS por km.

Gráfico 10. Bottom 5 regiones con diferencia entre el promdeio LGVS y HGVS



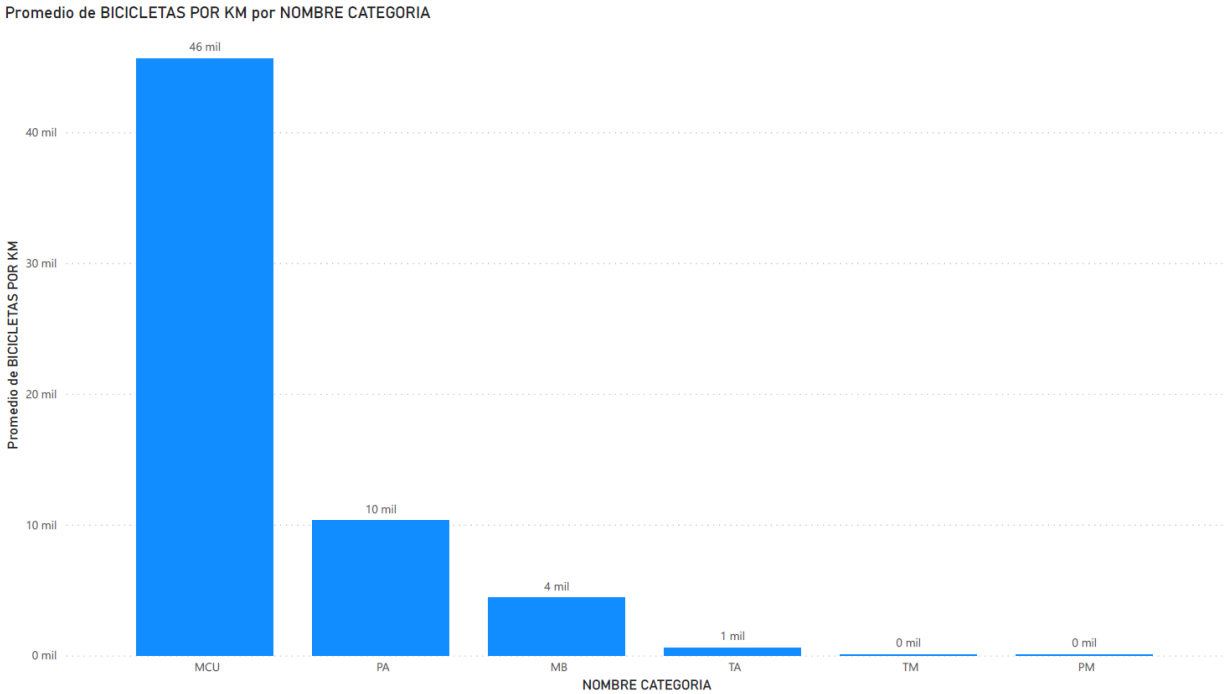
Estas son las cinco regiones con la menor diferencia entre la afluencia promedio por km de vehículos LGVS y HGVS.

Gráfico 11. Diferencia entre el promedio de LGVS por km y HGVS por km por categoría



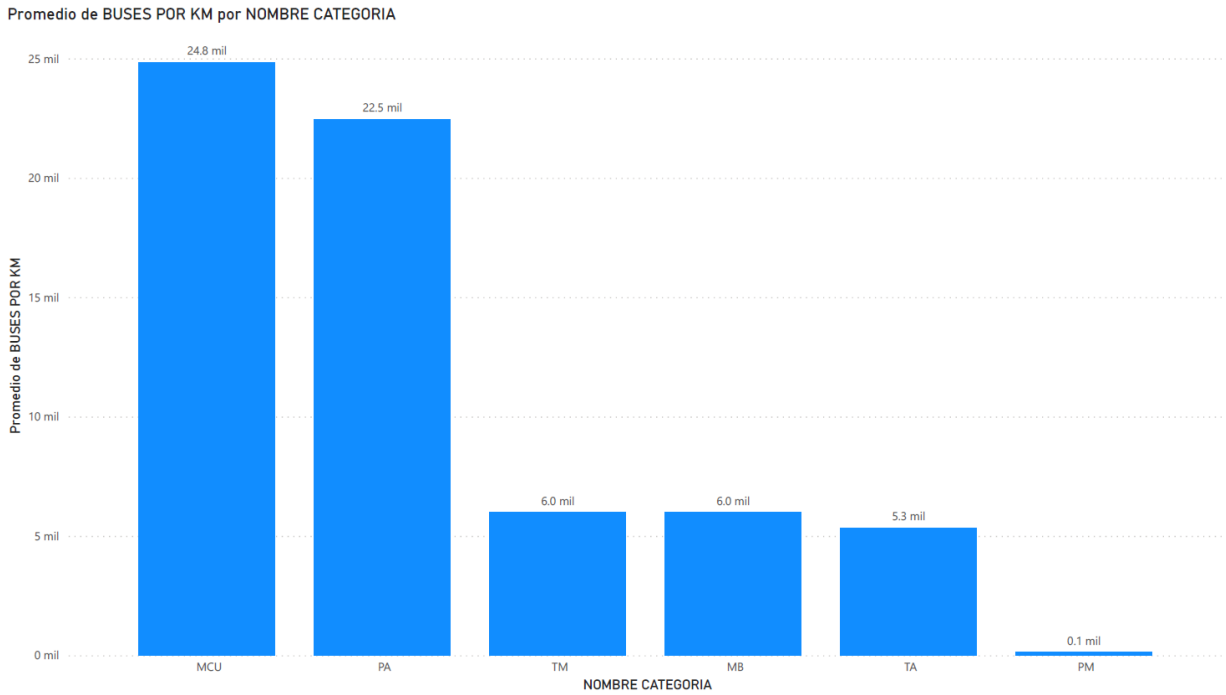
Observamos cómo se comporta la diferencia entre el promedio de LGVS por km y el promedio de HGVS por km según la categoría de la carretera.

Gráfico 12. Promedio de Bicicletas por km por categoría de carretera



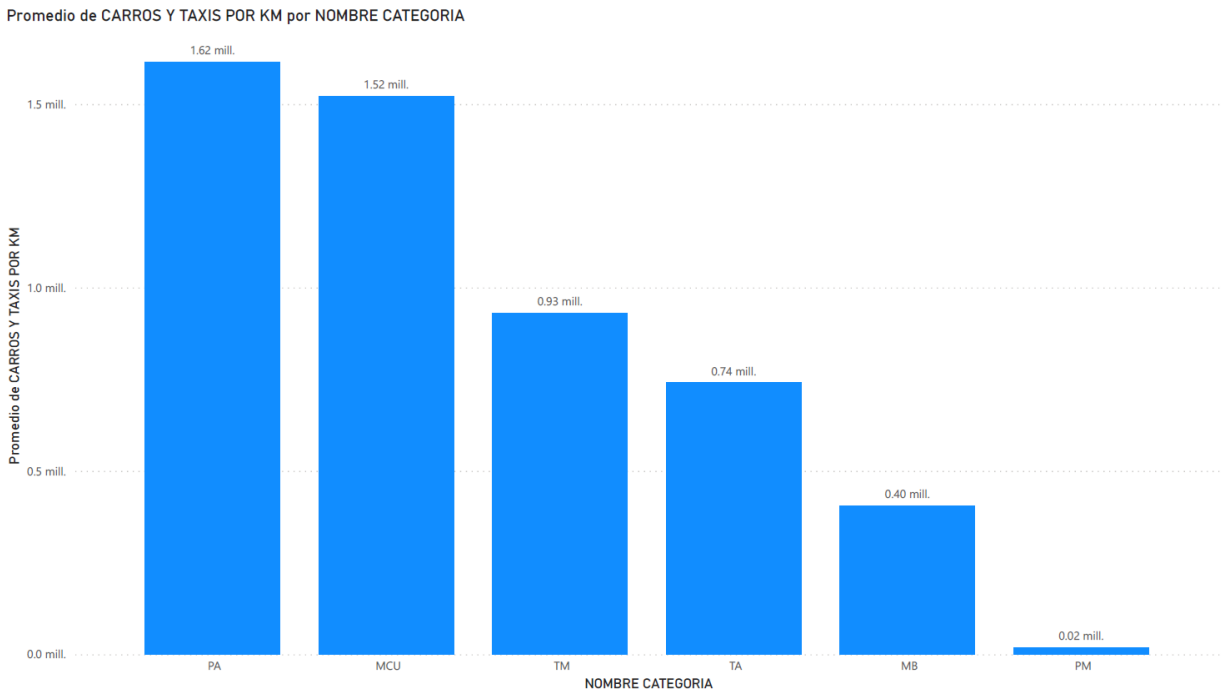
Se observa por categoría de carretera el promedio de bicicletas por km.

Gráfico 13. Promedio de Buses por km por categoría de carretera



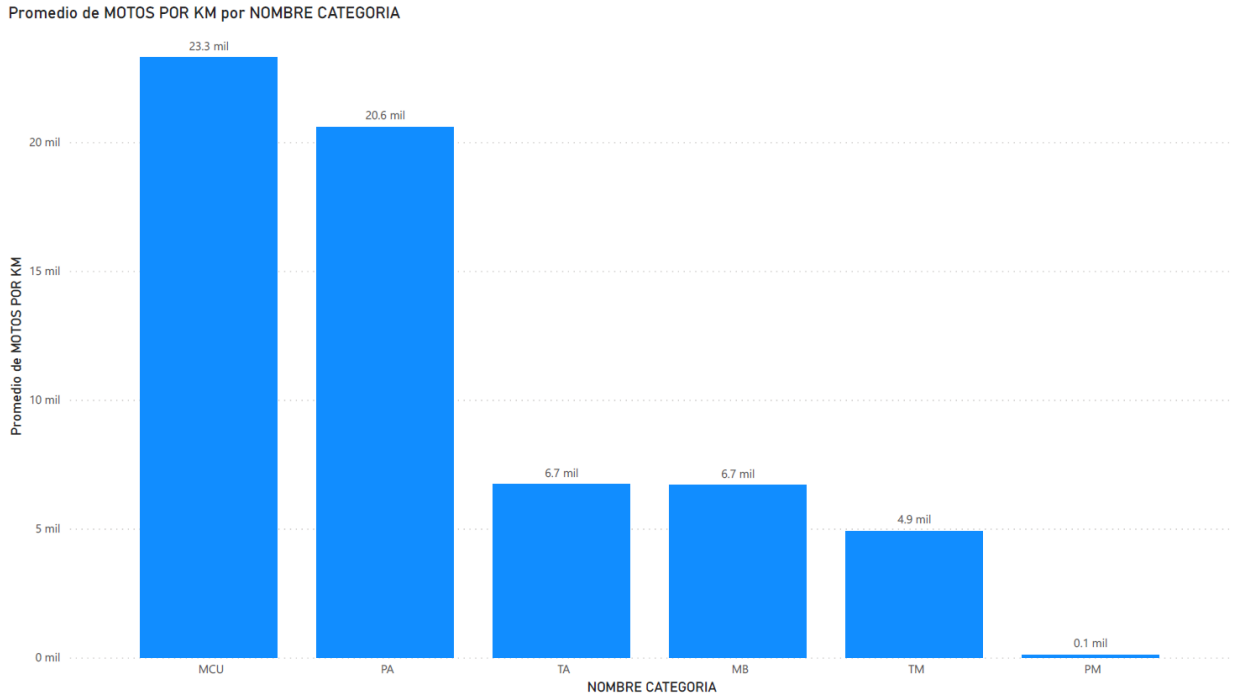
Se observa por categoría de carretera el promedio de buses por km.

Gráfico 14. Promedio de Carros y Taxis por km por categoría de carretera



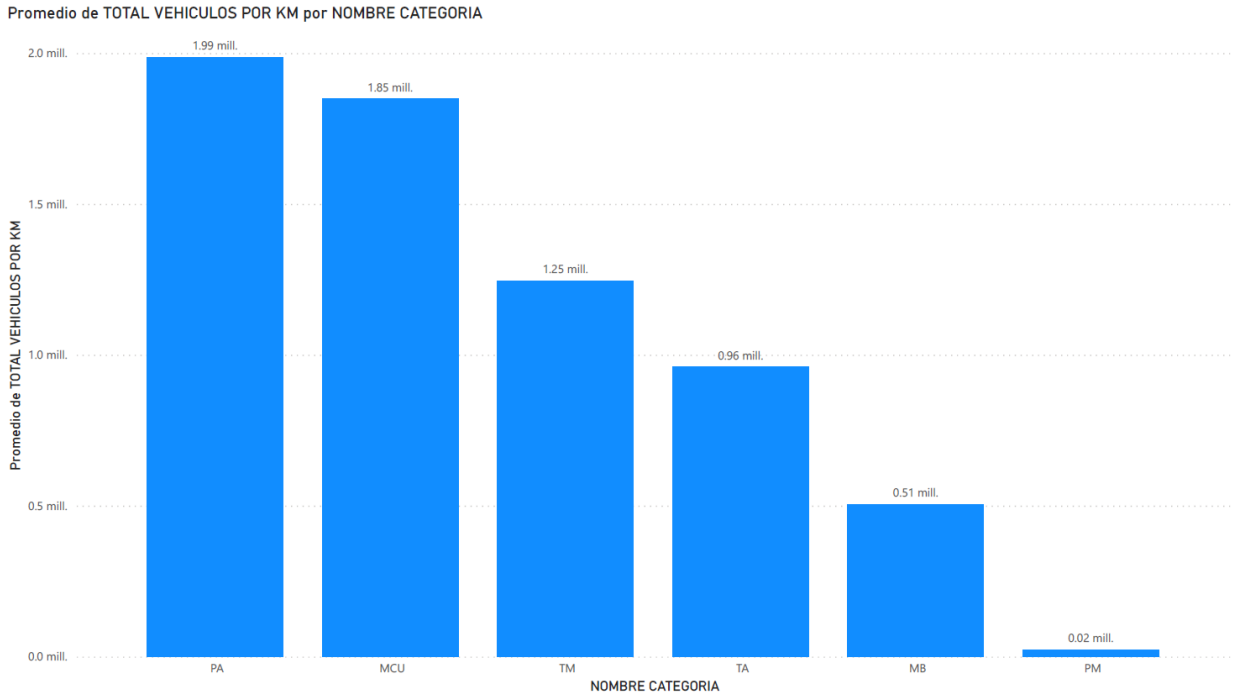
Se observa por categoría de carretera el promedio de carros y taxis por km.

Gráfico 15. Promedio de Motos por km por categoría de carretera



Se observa por categoría de carretera el promedio de motos por km.

Gráfico 16. Promedio del Total de Vehículos por km por categoría de carretera



Se observa por categoría de carretera el promedio del total de vehículos por km.

Simulación

Para iniciar, se realizó un EDA de los datos del flujo de tráfico para determinar las horas críticas. Es decir, las horas y el día de la semana en las que ocurre el flujo mayor y menor por medio de Power BI, suponiendo que, durante la recolección de datos, existió poca o nula variación entre los intervalos de la misma hora. Es decir, el flujo a las 7:05 es el mismo que a las 7:55, o esa fue la suposición que se realizó. Adicionalmente, se tomaron en cuenta los ceros como datos mal tomados, por lo que simplemente se omitieron.

Tabla 1. Promedios de acuerdo con la hora y el día de la semana.

Hora	1	2	3	4	5	6	7	Total
0	9.35	8.11	8.93	8.37	8.38	9.38	11.46	**9.18**
1	7.49	5.75	6.32	6.52	5.96	6.64	8.77	**6.83**
2	5.68	4.11	4.57	5.11	4.56	4.57	5.85	**4.97**
3	4.22	3.31	3.51	3.96	3.42	3.63	4.13	**3.77**
4	3.15	2.73	2.79	3.11	2.92	2.99	3.63	**3.06**
5	3.37	3.23	3.10	3.46	3.16	3.17	3.50	**3.29**
6	9.36	22.37	18.65	20.03	18.79	19.77	11.70	**16.98**
7	24.63	59.01	54.52	52.45	61.12	56.72	33.16	**47.79**
8	34.44	53.82	61.01	54.85	54.18	61.35	42.12	**51.12**
9	37.16	40.13	43.97	43.94	41.34	41.75	39.53	**41.02**
10	35.12	33.49	31.89	31.95	31.93	36.31	35.69	**33.76**
11	31.84	31.90	31.26	28.81	33.11	34.65	37.01	**32.64**
12	34.83	32.56	32.61	30.82	30.38	32.94	37.75	**33.25**
13	29.55	34.77	31.29	35.47	31.71	31.69	35.90	**32.87**
14	25.60	36.11	29.60	27.94	30.68	31.05	32.88	**30.41**
15	24.63	29.67	28.50	23.62	26.18	32.91	31.14	**28.00**
16	22.58	29.27	27.62	24.56	27.55	33.73	33.16	**28.23**
17	23.76	30.93	31.44	27.80	31.94	29.46	28.46	**28.91**
18	24.82	26.75	25.35	25.71	28.68	28.87	25.62	**26.38**
19	26.65	26.08	24.49	24.25	31.14	25.72	24.06	**25.83**
20	26.18	27.15	24.77	25.36	26.81	26.54	24.95	**25.90**
21	24.68	22.00	22.09	23.64	24.36	25.35	24.84	**23.81**
22	14.86	14.03	16.25	16.63	16.56	19.18	19.61	**16.68**
23	10.38	10.89	11.91	10.75	11.14	14.17	13.33	**11.78**
Total	**20.53**	**24.85**	**24.36**	**23.62**	**25.03**	**26.07**	**23.84**	**23.89**

Una vez determinados los tiempos de mayor y menor tránsito, se realizaron histogramas para determinar si es válido tomarlos como Poisson y los tiempos de llegada, como exponencial. Aunque las gráficas no sean exactamente así, se asemejan bastante en la mayoría de los casos y debido a la naturaleza de los datos, se tomaron de esta manera para la simulación. Estos gráficos se encuentran en el archivo 'EDA Traffic Flow Proyecto' de Power BI adjunto.

Sobre los datos de trafico proporcionados se pudo determinar de forma gráfica que no hay una variación significativa en el flujo vehicular por hora respecto al día. Hay una variación en la media de flujo por hora con un máximo de 26 carros por hora y un mínimo de 21 carros por hora. La verdadera diferencia la da el flujo vehicular por hora independiente del día este es el que realmente sirve para el estudio ya que se presentan variaciones de tráfico vehicular mucho más fuertes. Con un mínimo de carros circulando cada 5 minutos de 3 carros el cual es el caso de las 4am y un máximo de 51 carros a las 8am.

El EDA realizado permitió determinar la cantidad de vehículos que pasan. Estos valores fueron los utilizados como lambda y mediante una simulación de 200 iteraciones por lambda se determinó el valor esperado de flujo vehicular por minuto, tanto por día como por hora. El valor esperado se encuentra dado en vehículos/minuto es decir cuanto tiempo se tarda uno entre otro vehículo en pasar. La gráfica 17

muestra de igual forma que el análisis EDA que el flujo vehicular es constante respecto a los días con un valor esperado máximo de 0.27 min entre vehículos y un mínimo de 0.19 min entre vehículos, en cambio las horas si tienen una gran variación. Como lo muestra el gráfico 18 las horas previo a las 6am son las que tiene una mayor separación de tiempos entre cada llegada de un vehículo haciendo énfasis en las 4am y 5am con valores de 1.46 min entre llegadas y 1.58 min entre llegadas respectivamente. Esto es de esperarse ya que son las horas previo al inicio de labores de muchas personas.

Gráfico 17: Valor esperado de tiempo de paso entre vehículos por día de la semana

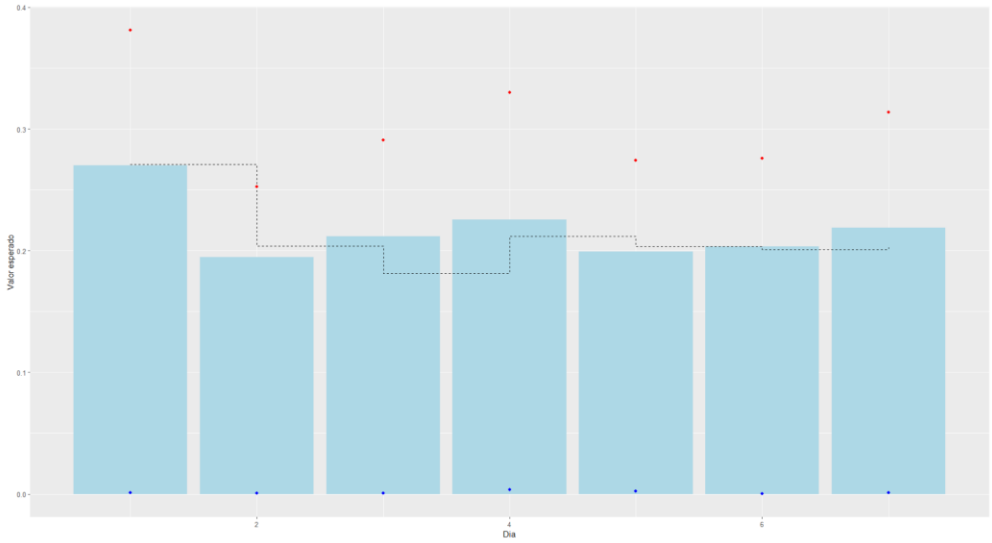
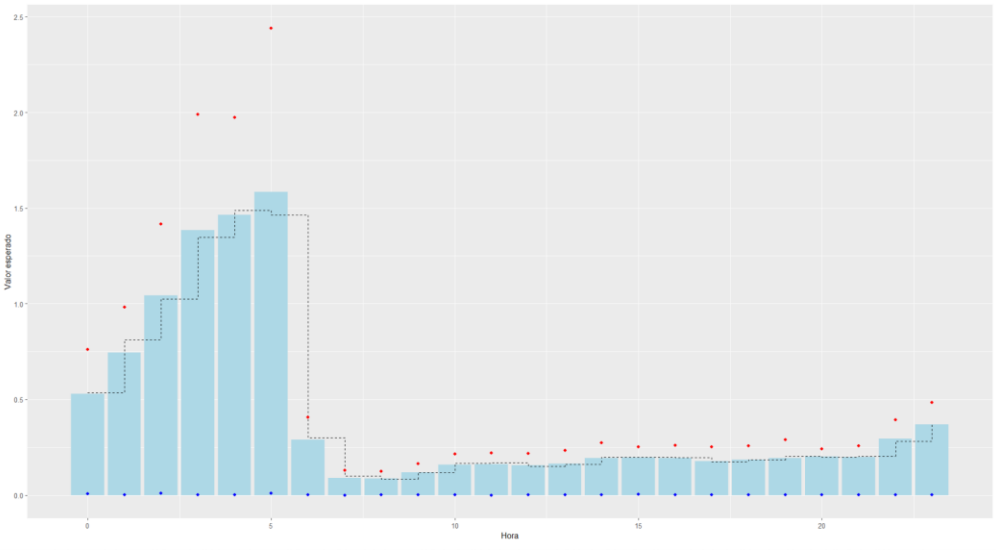


Gráfico 18: Valor esperado de tiempo de paso entre vehículos por hora del día



En los horarios de 4am y 5am se tiene una probabilidad de ocurrencia de llegada de vehículos similar. Esto se muestra con las gráficas no y no donde en ambas horas se tiene una probabilidad mayor a 40% de que

no pase ningún vehículo en periodos de 5 min. Esto muestra que este es el mejor horario para realizar los trabajos y evitar tráfico, se recomienda que dichos trabajos se hagan por carril para seguir dejando pasar vehículos.

Gráfico 19: Probabilidad de llegada de vehículos en periodos de 5minutos a las 4am

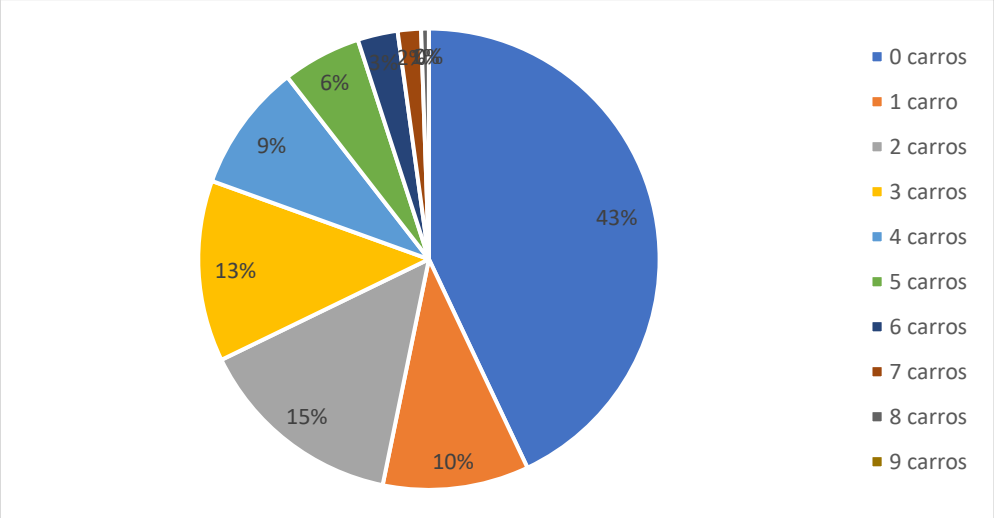
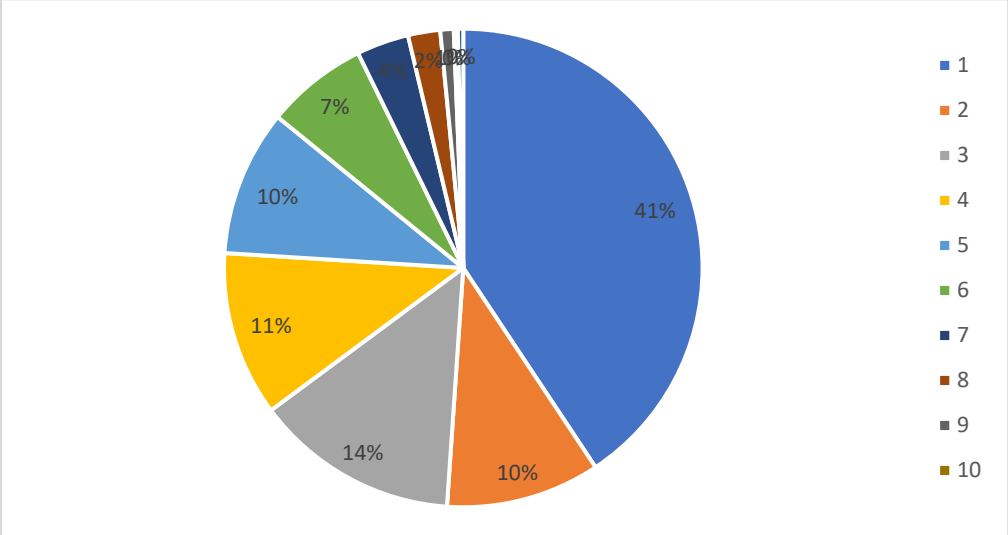


Gráfico 20: Probabilidad de llegada de vehículos en periodos de 5minutos a las 5am



Conclusiones

- No hay carreteras de tipo B que necesiten mejoras urgentes debido a que no hay datos atípicos en su distribución
- Las horas más transcurridas son entre semana, las 7 y las 8 de la mañana.
- Las horas con menor flujo de vehículos son las 4am y 5am. Posterior a esto el flujo se mantiene alto hasta las 22 horas

- El flujo es muy grande durante todo el tiempo para considerar cerrar la carretera completamente, pero de hacer arreglos se recomienda hacerlos cerrando la carretera parcialmente y a las 4 de la mañana

Bibliografía

No hay ninguna fuente en el documento actual.

Anexos

- Análisis de datos por medio de Python en Google Colab

https://colab.research.google.com/drive/1UPawxAf2d1b3AVD2raUn3MpbjnX26Yew?usp=sharing

- Análisis de datos de Power BI del flujo de tráfico (Archivo Traffic_Flow), adjunto a tarea en Canvas
- Memoria de cálculo para análisis de probabilidad de flujo vehicular en horas de construcción adjunto en formato Excel en tarea.